

# 梯度下降法

- **梯度下降法** (gradient descent) 或**最速下降法** (steepest descent)：是求解无约束最优化问题常用方法；是迭代算法，每一步求解目标函数的梯度向量；
- 设 $f(x)$ 是 $\mathbb{R}^n$ 上具有一阶连续偏导的函数，无约束最优化问题是 ( $x^*$ 表示极小值点)：

$$\min_{x \in \mathbb{R}^n} f(x) \quad (1)$$

- **算法思路**：由于负梯度方向是使函数值下降最快的方向，在迭代的每一步以负梯度方向更新 $x$ 的值，从而达到减少函数值的目的（极小化）；
- 由于 $f(x)$ 一阶连续可导，在第 $k$ 次迭代值为 $x^{(k)}$ ，可将 $f(x)$ 在 $x^{(k)}$ 附近进行一阶泰勒展开：

$$f(x) = f(x^{(k)}) + g_k^T (x - x^{(k)}) \quad (2)$$

其中 $g_k = g(x^{(k)}) = \nabla f(x^{(k)})$ 表示 $f(x)$ 在 $x^{(k)}$ 的梯度；

- 求出第 $k + 1$ 次的迭代值：

$$x^{(k+1)} \leftarrow x^{(k)} + \lambda_k p_k \quad (3)$$

其中 $p_k$ 是搜索方向，取负梯度方向 $p_k = -\nabla f(x^{(k)})$ ； $\lambda_k$ 是步长，由一维搜索确定，即 $\lambda_k$ 使得 $f(x^{(k)} + \lambda_k p_k) = \min_{\lambda \geq 0} f(x^{(k)} + \lambda p_k)$ 成立；

- **梯度下降算法**：

1. **输入**目标函数 $f(x)$ ，梯度函数 $g(x) = \nabla f(x)$ ，计算精度 $\epsilon$ ；
2. 初始化 $x^{(0)} \in \mathbb{R}^n$ 的值， $k = 0$ ；
3. 计算 $f(x^{(k)})$ ；
4. 计算梯度 $g_k = g(x^{(k)}) = \nabla f(x^{(k)})$ ，当 $\|g_k\| < \epsilon$ 时停止迭代，令 $x^* = x^{(k)}$ ；否则令 $p_k = -g_k$ ，求 $\lambda_k$ 使 $f(x^{(k)} + \lambda_k p_k) = \min_{\lambda \geq 0} f(x^{(k)} + \lambda p_k)$ ；

5. 更新 $x^{(k+1)} \leftarrow x^{(k)} + \lambda_k p_k$ , 计算 $f(x^{(k+1)})$ , 当 $\|f(x^{(k+1)}) - f(x^{(k)})\| < \epsilon$  或 $\|x^{(k+1)} - x^{(k)}\| < \epsilon$ 时停止迭代, 令 $x^* = x^{(k)}$ ;
6. 否则 $k = k + 1$ , 回到步骤 (4) ;
7. **输出**极小点 $x^*$ ;

- 当目标函数是~~凸函数~~时, 梯度下降的解是~~全局最优解~~; 一般情况下不保证是全局最优解;
- 梯度下降法的收敛速度未必很快;