

牛顿法和拟牛顿法

牛顿法和拟牛顿法

1. 牛顿法
2. 拟牛顿法思路
3. DFP算法
4. BFGS算法
5. Broyden类算法

- **牛顿法** (Newton method) 和**拟牛顿法** (Quasi-Newton method) 也是求解无约束最优化问题常用方法，优点是收敛速度快；
- 牛顿法迭代的每一步需要求解目标函数的海森矩阵的逆矩阵，复杂度高；
- 拟牛顿法通过正定矩阵近似海森矩阵的逆矩阵或海森矩阵，简化计算；

1. 牛顿法

- 考虑无约束最优化问题 (x^* 表示极小值点)：

$$\min_{x \in \mathbb{R}^n} f(x) \quad (1)$$

假设 $f(x)$ 具有二阶连续偏导数，在第 k 次迭代值为 $x^{(k)}$ ，可将 $f(x)$ 在 $x^{(k)}$ 附近进行二阶泰勒展开：

$$f(x) = f(x^{(k)}) + g_k^T (x - x^{(k)}) + \frac{1}{2} (x - x^{(k)})^T H_k (x - x^{(k)}) \quad (2)$$

其中 $g_k = g(x^{(k)}) = \nabla f(x^{(k)})$ 表示 $f(x)$ 在 $x^{(k)}$ 的梯度向量的值， $H_k = H(x^{(k)})$ 是 $f(x)$ 的**海森矩阵** (Hessian matrix) $H(x) = \left[\frac{\partial^2 f}{\partial x_i \partial x_j} \right]_{n \times n}$ 在点 $x^{(k)}$ 的值；

- **算法思路**：函数 $f(x)$ 有极值的必要条件是在极值点处一阶导为0，即梯度向量为0，特别是当 $H(x^{(k)})$ 是正定矩阵时，该极值点是极小值点；牛顿法利用极小值的

必要条件 ($\nabla f(x) = 0$) , 迭代时从点 $x^{(k)}$ 出发, 求目标函数的极小点作为第 $k + 1$ 次迭代值 $x^{(k+1)}$;

- 假设 $x^{(k+1)}$ 满足 $\nabla f(x^{(k+1)}) = 0$, 根据泰勒展开式有:

$$\nabla f(x) = g_k + H_k(x - x^{(k)}) \quad (3)$$

代入可得:

$$g_k + H_k(x^{(k+1)} - x^{(k)}) = 0 \quad (4)$$

即

$$x^{(k+1)} = x^{(k)} + p_k \quad (5)$$

其中 $p_k = -H_k^{-1} g_k$;

- **牛顿法算法流程:**

1. **输入** 目标函数 $f(x)$, 梯度 $g(x) = \nabla f(x)$, 海森矩阵 $H(x)$, 精度要求 ϵ ;
2. 取初始点 $x^{(0)}$, $k = 0$;
3. 计算梯度 $g_k = g(x^{(k)}) = \nabla f(x^{(k)})$, 当 $\|g_k\| < \epsilon$ 时停止迭代, 令 $x^* = x^{(k)}$; 否则进入下一步 ;
4. 计算 $H_k = H(x^{(k)})$, 求 $p_k = -H_k^{-1} g_k$;
5. 更新 $x^{(k+1)} = x^{(k)} + p_k$, $k = k + 1$, 重复步骤 (3) ;
6. **输出** 极小值点 x^* ;

- 上述流程中步骤 (4) 需要求 H_k^{-1} , 计算比较复杂;

2. 拟牛顿法思路

- **算法思路:** 考虑用一个 n 阶矩阵 $G_k = G(x^{(k)})$ 来近似替代 $H_k^{-1} = H^{-1}(x^{(k)})$;
- 在牛顿法中, 海森矩阵 H_k 满足以下条件 (根据泰勒展开式) :

$$g_{k+1} - g_k = H_k(x^{(k+1)} - x^{(k)}) \quad (6)$$

记 $y_k = g_{k+1} - g_k$, $\delta_k = x^{(k+1)} - x^{(k)}$, 那么 $y_k = H_k \delta_k$ 或 $H_k^{-1} y_k = \delta_k$ 称为**拟牛顿条件**;

- 如果 H_k 是正定的 (H_k^{-1} 也是正定) , 那么可以保证牛顿法搜索方向是下降的, 因为搜索方向是 $p_k = -H_k^{-1}g_k$, 有

$$x = x^{(k)} + \lambda p_k = x^{(k)} - \lambda H_k^{-1}g_k \quad (7)$$

而 $f(x)$ 在 $x^{(k)}$ 的泰勒展开式近似写成:

$$f(x) = f(x^{(k)}) - \lambda g_k^T H_k^{-1}g_k \quad (8)$$

因为 H_k^{-1} 正定, $g_k^T H_k^{-1}g_k > 0$; 当 λ 是一个充分小的正数时, 总有 $f(x) < f(x^{(k)})$, 也即证明了 p_k 是下降方向;

- 拟牛顿法将 G_k 作为 H_k^{-1} 的近似 (或者 B_k 逼近 H_k) , 要求矩阵 G_k 满足同样条件: 1) 每次迭代 G_k 是正定的; 2) 满足拟牛顿条件 $G_k y_k = \delta_k$;
- 按照拟牛顿条件, 每次迭代中选择更新矩阵: $G_{k+1} = G_k + \Delta G_k$, 根据不同具体实现产生多种算法

3. DFP算法

- **DFP算法** (Davidon-Fletcher-Powell algorithm) 选择 G_{k+1} 思路: 假设每次迭代矩阵 G_{k+1} 由 G_k 加上两个附加项 (待定矩阵) 构成

$$G_{k+1} = G_k + P_k + Q_k \quad (9)$$

- 因此有:

$$G_{k+1}y_k = G_k y_k + P_k y_k + Q_k y_k \quad (10)$$

为了使 G_{k+1} 满足拟牛顿条件, 可使待定矩阵满足

$$\begin{aligned} P_k y_k &= \delta_k \\ Q_k y_k &= -G_k y_k \end{aligned}$$

可以容易地找出这样的 P_k 和 Q_k :

$$\begin{aligned} P_k &= \frac{\delta_k \delta_k^T}{\delta_k^T y_k} \\ Q_k &= -\frac{G_k y_k y_k^T G_k}{y_k^T G_k y_k} \end{aligned}$$

- 所以 G_{k+1} 的迭代更新公式为：

$$G_{k+1} = G_k + \frac{\delta_k \delta_k^T}{\delta_k^T y_k} - \frac{G_k y_k y_k^T G_k}{y_k^T G_k y_k} \quad (11)$$

- **可证明：**如果初始矩阵 G_0 是正定的，则迭代时 G_k 都是正定的；

• DFP算法流程：

1. 输入**目标函数 $f(x)$ ，梯度 $g(x) = \nabla f(x)$ ，精度要求 ϵ ；
2. 取初始点 $x^{(0)}$ ，取 G_0 为正定对称矩阵， $k = 0$ ；
3. 计算梯度 $g_k = g(x^{(k)}) = \nabla f(x^{(k)})$ ，当 $\|g_k\| < \epsilon$ 时停止迭代，令 $x^* = x^{(k)}$ ，否则进入下一步；
4. 求 $p_k = -G_k g_k$ ；
5. 一维搜索，求 λ_k 使其满足 $f(x^{(k)} + \lambda_k p_k) = \min_{\lambda \geq 0} f(x^{(k)} + \lambda p_k)$ ；
6. 更新 $x^{(k+1)} = x^{(k)} + \lambda_k p_k$ ；
7. 计算梯度 $g_{k+1} = g(x^{(k+1)}) = \nabla f(x^{(k+1)})$ ，当 $\|g_{k+1}\| < \epsilon$ 时停止迭代，令 $x^* = x^{(k+1)}$ ，否则计算 G_{k+1} ：

$$G_{k+1} = G_k + \frac{\delta_k \delta_k^T}{\delta_k^T y_k} - \frac{G_k y_k y_k^T G_k}{y_k^T G_k y_k} \quad (12)$$

8. $k = k + 1$ ，重复步骤（4）；
9. **输出**极小值点 x^* ；

4. BFGS算法

- **BFGS算法**（Broyden-Fletcher-Goldfarb-Shanno algorithm）：是最流行的拟牛顿算法，考虑用 B_k 逼近海森矩阵 H_k ；
- 相应的拟牛顿条件：

$$B_{k+1} \delta_k = y_k \quad (13)$$

同样地假设迭代矩阵 B_{k+1} 满足：

$$\begin{aligned} B_{k+1} &= B_k + P_k + Q_k \\ B_{k+1} \delta_k &= B_k \delta_k + P_k \delta_k + Q_k \delta_k \end{aligned}$$

可以考虑这样的 P_k 和 Q_k ：

$$\begin{aligned} P_k \delta_k &= y_k \\ Q_k \delta_k &= -B_k \delta_k \end{aligned}$$

- 找到 B_{k+1} 的迭代更新公式为：

$$B_{k+1} = B_k + \frac{y_k y_k^T}{y_k^T \delta_k} - \frac{B_k \delta_k \delta_k^T B_k}{\delta_k^T B_k \delta_k} \quad (14)$$

- **可证明：**如果初始矩阵 B_0 是正定的，则迭代时 B_k 都是正定的；

- **BFGS算法流程：**

1. 输入目标函数 $f(x)$ ，梯度 $g(x) = \nabla f(x)$ ，精度要求 ϵ ；
2. 取初始点 $x^{(0)}$ ，取 B_0 为正定对称矩阵， $k = 0$ ；
3. 计算梯度 $g_k = g(x^{(k)}) = \nabla f(x^{(k)})$ ，当 $\|g_k\| < \epsilon$ 时停止迭代，令 $x^* = x^{(k)}$ ，否则进入下一步；
4. 由 $B_k p_k = -g_k$ 求 p_k ；
5. 一维搜索，求 λ_k 使其满足 $f(x^{(k)} + \lambda_k p_k) = \min_{\lambda \geq 0} f(x^{(k)} + \lambda p_k)$ ；
6. 更新 $x^{(k+1)} = x^{(k)} + \lambda_k p_k$ ；
7. 计算梯度 $g_{k+1} = g(x^{(k+1)}) = \nabla f(x^{(k+1)})$ ，当 $\|g_{k+1}\| < \epsilon$ 时停止迭代，令 $x^* = x^{(k+1)}$ ，否则计算 B_{k+1} ：

$$B_{k+1} = B_k + \frac{y_k y_k^T}{y_k^T \delta_k} - \frac{B_k \delta_k \delta_k^T B_k}{\delta_k^T B_k \delta_k} \quad (15)$$

8. $k = k + 1$ ，重复步骤（4）；
9. 输出极小值点 x^* ；

5. Broyden类算法

- 在BFGS算法中 B_k 的迭代公式中，如果记 $G_k = B_k^{-1}$ ， $G_{k+1} = B_{k+1}^{-1}$ ，那么对迭代式（14）应用两次**Sherman-Morrison公式**可得：

$$G_{k+1} = \left(I - \frac{\delta_k y_k^T}{\delta_k^T y_k} \right) G_k \left(I - \frac{\delta_k y_k^T}{\delta_k^T y_k} \right)^T + \frac{\delta_k \delta_k^T}{\delta_k^T y_k} \quad (16)$$

称为BFGS算法关于 G_k 的迭代公式;

- 由DFP算法得到的 G_{k+1} 记作 G^{DFP} , 由BFGS算法得到的 G_{k+1} 记作 G^{BFGS} , 都满足拟牛顿条件, 所以他们的线性组合
 $G_{k+1} = \alpha G^{\text{DFP}} + (1 - \alpha) G^{\text{BFGS}}, 0 \leq \alpha \leq 1$ 也满足拟牛顿条件, 而且正定;
- 于是就得到了一类拟牛顿法, 称为Broyden类算法;

Sherman-Morrison公式: 假设 A 是 n 阶可逆矩阵, u, v 是 n 维向量, 且 $A + uv^T$ 也是可逆矩阵, 则有:

$$(A + uv^T)^{-1} = A^{-1} - \frac{A^{-1}uv^T A^{-1}}{1 + v^T A^{-1}u} \quad (17)$$