

支持向量机

支持向量机

7.3 非线性支持向量机与核函数

7.3.1 核技巧

1. 非线性分类问题
2. 核函数的定义
3. 核技巧在支持向量机中的应用

7.3.2 正定核

7.3.3 常用核函数

1. 多项式核函数 (polynomial kernel function)
2. 高斯核函数 (Gaussian kernel function)
3. 字符串核函数 (string kernel function)

7.3.4 非线性支持向量机

7.3 非线性支持向量机与核函数

7.3.1 核技巧

1. 非线性分类问题

- **非线性分类问题**是指通过利用非线性模型才能很好地进行分类的问题；
- 对于训练集 T ，如果能用 \mathbb{R}^n 中的一个超曲面将正负例正确分开，则称问题为**非线性可分问题**；
- 例子：设原空间为 $\mathcal{X} \subset \mathbb{R}^2$, $x = (x^{(1)}, x^{(2)})^T \in \mathcal{X}$ ，新空间 $\mathcal{Z} \subset \mathbb{R}^2$, $z = (z^{(1)}, z^{(2)})^T \in \mathcal{Z}$ ，定义从原空间到新空间的变换（映射）：

$$z = \phi(x) = ((x^{(1)})^2, (x^{(2)})^2)^T \quad (1)$$

原空间中的点相应地变成新空间中的点，原空间中的椭圆变成新空间的直线，且可以将变换后的正负实例点正确分开；

- 用线性分类法求解非线性分类问题：1) 使用一个变换将原空间的数据映射到新空间；2) 在新空间中用线性分类学习方法从训练数据中学习模型；
- **核技巧**应用到支持向量机：通过一个非线性变换将输入空间（欧式空间 \mathbb{R}^n 或离散集合）对应到一个特征空间（希尔伯特空间 \mathcal{H} ），使得在输入空间中的超曲面模型对应于特征空间的超平面模型；

2. 核函数的定义

- **核函数定义**：设 \mathcal{X} 是输入空间（欧式空间 \mathbb{R}^n 或离散集合），而 \mathcal{H} 为特征空间（希尔伯特空间），如果存在一个从 \mathcal{X} 到 \mathcal{H} 的映射：

$$\phi(x) : \mathcal{X} \rightarrow \mathcal{H} \quad (2)$$

使得对所有的 $x, z \in \mathcal{X}$ ，函数 $K(x, z)$ 满足条件：

$$K(x, z) = \phi(x) \cdot \phi(z) \quad (3)$$

则称 $K(x, z)$ 为核函数， $\phi(x)$ 为映射函数；

- 核技巧的想法：在学习和预测中只定义核函数 $K(x, z)$ ，而不显式地定义映射函数 ϕ ；通常直接计算 $K(x, z)$ 容易，而通过 $\phi(x)$ 和 $\phi(z)$ 计算 $K(x, z)$ 不容易；
- 对于给定核 $K(x, z)$ ，特征空间 \mathcal{H} 和映射函数 ϕ 取法不唯一，可以取不同的特征空间，在同一特征空间也可以取不同的映射；

3. 核技巧在支持向量机中的应用

- 注意到在线性支持向量机的对偶问题中，无论是目标函数还是决策函数，都只涉及输入实例与实例之间的内积；
- 在对偶问题的目标函数中的内积 $x_i \cdot x_j$ 可以用核函数 $K(x_i, x_j) = \phi(x_i) \cdot \phi(x_j)$ 代替，变为

$$W(\alpha) = \frac{1}{2} \sum_{i=1}^N \sum_{j=1}^N \alpha_i \alpha_j y_i y_j K(x_i, x_j) - \sum_{i=1}^N \alpha_i \quad (4)$$

- 同样分类决策函数中的内积也可以用核函数代替，变成

$$f(x) = \text{sign} \left(\sum_{i=1}^N \alpha_i^* y_i K(x_i, x) + b^* \right) \quad (5)$$

- 这样等价于经过映射函数 ϕ 将原来的输入空间变换到一个新的特征空间中，将输入空间的内积变成特征空间的内积 $\phi(x_i) \cdot \phi(x_j)$ ，在特征空间中学习线性支持向量机；
- 当映射函数是非线性函数时，学习到的含有核函数的支持向量化就是非线性分类模型；
- 学习是隐式地在特征空间进行的，不需要显式地定义特征空间和映射函数--核技巧；

7.3.2 正定核

- 通常所说的核函数都是**正定核函数** (positive definite kernel function) ；
- 假设 $K(x, z)$ 是定义在 $\mathcal{X} \times \mathcal{X}$ 上的对称函数，且对于任意的 $x_1, x_2, \dots, x_m \in \mathcal{X}$ ， $K(x, z)$ 关于 x_1, x_2, \dots, x_m 的Gram矩阵（第一章感知机用于存储训练集内积的矩阵）是半正定的，可以依据函数 $K(x, z)$ 构成一个希尔伯特空间（Hilbert space）：

1. 定义映射 ϕ 并构成向量空间 \mathcal{S}

- 定义映射： $\phi : x \rightarrow K(\cdot, x)$ ；
- 对于任意的 $x_i \in \mathcal{X}$ ， $\alpha_i \in \mathbb{R}, i = 1, 2, \dots, m$ ，定义线性组合：
 $f(\cdot) = \sum_{i=1}^m \alpha_i K(\cdot, x_i)$ ；
- 考虑由线性组合为元素的集合 \mathcal{S} ，由于集合对加法和数乘运算封闭，所以 \mathcal{S} 构成一个向量空间；

2. 在 \mathcal{S} 上定义内积构成内积空间

- 在 \mathcal{S} 上对于任意的 $f(\cdot) = \sum_{i=1}^m \alpha_i K(\cdot, x_i), g(\cdot) = \sum_{j=1}^l \beta_j K(\cdot, x_j)$ ，定义运算 $*$ ：

$$f * g = \sum_{i=1}^m \sum_{j=1}^l \alpha_i \beta_j K(x_i, x_j) \quad (6)$$

- 可以证明运算 $*$ 是空间 \mathcal{S} 的内积，即满足下面条件：

- (1) $(cf) * g = c(f * g), c \in \mathbb{R}$
- (2) $(f + g) * h = f * h + g * h, h \in \mathcal{S}$
- (3) $f * g = g * f$
- (4) $f * f \geq 0$
- (5) $f * f = 0 \Leftrightarrow f = 0$

- 赋予内积的空间为内积空间，因此 \mathcal{S} 是一个内积空间， $*$ 是 \mathcal{S} 内积运算，仍然可以写成：

$$f \cdot g = \sum_{i=1}^m \sum_{j=1}^l \alpha_i \beta_j K(x_i, z_j) \quad (7)$$

3. 将 \mathcal{S} 完备化构成希尔伯特空间

- 由定义的内积可以得到范数： $\|f\| = \sqrt{f \cdot f}$ ，因此 \mathcal{S} 是一个**赋范向量空间**；
- 根据泛函分析理论，对于不完备的赋范向量空间，一定可以使之完备化，得到完备的赋范向量空间 \mathcal{H} ；
- 一个内积空间，当作为一个赋范向量空间是完备时，就是希尔伯特空间；
- 这样的希尔伯特空间 \mathcal{H} ，称为再生核希尔伯特空间（reproducing kernel Hilbert space, RKHS），这是由于核 K 具有再生性，满足

$$\begin{aligned} (1) \quad & K(\cdot, x) \cdot f = f(x) \\ (2) \quad & K(\cdot, x) \cdot K(\cdot, z) = K(x, z) \end{aligned} \quad (8)$$

的称为再生核；

4. 正定核的充要条件

- **正定核的充要条件**：设 $K : \mathcal{X} \times \mathcal{X} \rightarrow \mathbb{R}$ 是对称函数，则 $K(x, z)$ 为正定核函数的充要条件是对任意 $x_i \in \mathcal{X}$ ， $K(x, z)$ 对应的Gram矩阵：

$$K = [K(x_i, x_j)]_{m \times m} \quad (9)$$

是半正定矩阵；

- **正定核的定价定义**：设 $\mathcal{X} \subset \mathbb{R}^n$ ， $K(x, z)$ 是定义在 $\mathcal{X} \times \mathcal{X}$ 上的对称函数，如果对于任意 $x_i \in \mathcal{X}$ ， $K(x, z)$ 对于的Gram矩阵是半正定矩阵，则称 $K(x, z)$ 是正定核；
- 该定义在构造核函数时很有用，但对于一个具体函数 $K(x, z)$ ，检验是否为正定核函数并不容易（因为要对任意有限输入集验证 K 对于的Gram矩阵是否半正定），因此在实际中往往应用已有的核函数；

7.3.3 常用核函数

1. 多项式核函数（polynomial kernel function）

$$K(x, z) = (x \cdot z + 1)^p \quad (10)$$

- 对应的支持向量机是一个 p 次多项式分类器，分类决策函数成为：

$$f(x) = \text{sign} \left(\sum_{i=1}^N \alpha_i^* y_i (x_i \cdot x + 1)^p + b^* \right) \quad (11)$$

2. 高斯核函数 (Gaussian kernel function)

$$K(x, z) = \exp \left(-\frac{\|x - z\|^2}{2\sigma^2} \right) \quad (12)$$

- 对于的支持向量机是高斯径向基函数 (radial basis function) 分类器，分类决策函数成为：

$$f(x) = \text{sign} \left(\sum_{i=1}^N \alpha_i^* y_i \exp \left(-\frac{\|x - x_i\|^2}{2\sigma^2} \right) + b^* \right) \quad (13)$$

3. 字符串核函数 (string kernel function)

- 核函数不仅可以定义在欧式空间上，还可以是离散数据的集合（字符串核定义在字符串集合上，用于文本分类、信息检索、生物信息等）；
- 考虑一个有限字符表 Σ ，字符串 s 是从中取出的有限个字符的序列（包括空字符串），字符串 s 的长度用 $|s|$ 表示，元素记作 $s(1), s(2), \dots, s(|s|)$ ，两个字符串 s 和 t 的连接记作 st ，所有长度为 n 的字符串的集合记作 Σ^n ，所有字符串的集合记作 $\Sigma^* = \bigcup_{n=0}^{\infty} \Sigma^n$ ；
- 考虑字符串 s 的子串 u ，给定一个指标序列
 $i = (i_1, i_2, \dots, i_{|u|}), 1 \leq i_1 < i_2 < \dots < i_{|u|} \leq |S|$ ， s 的子串定义为
 $u = s(i) = s(i_1) \cdots s(i_{|u|})$ ，其长度记作 $l(i) = i_{|u|} - i_1 + 1$ ，如果 i 是连续的，则 $l(i) = |u|$ ，否则 $l(i) > |u|$ ；
- 假设 S 是长度大于或等于 n 字符串集合， s 是 S 的元素，现在建立字符串集合 S 到特征空间 $\mathcal{H}_n = \mathbb{R}^{\Sigma^n}$ 的映射 $\phi_n(s)$ ， \mathbb{R}^{Σ^n} 表示定义在 Σ^n 上的实数空间，其每一维对应一个字符串 $u \in \Sigma^n$ ，映射将字符串 s 对应于空间 \mathbb{R}^{Σ^n} 的一个向量，其在 u 维上的取值为

$$[\phi_n(s)]_u = \sum_{i:s(i)=u} \lambda^{l(i)} \quad (14)$$

其中 $0 \leq \lambda \leq 1$ 是一个衰减参数， $l(i)$ 表示字符串 i 长度，求和在 s 中所有与 u 相同的子串上进行；

- 两个字符串 s 和 t 上的字符串核函数是基于映射 ϕ_n 的特征空间中的内积：

$$k_n(s, t) = \sum_{u \in \Sigma^n} [\phi_n(s)]_u [\phi_n(t)]_u = \sum_{u \in \Sigma^n} \sum_{(i,j): s(i)=t(j)=u} \lambda^{l(i)} \lambda^{l(j)} \quad (15)$$

字符串核函数 $k_n(s, t)$ 给出了两字符串中长度等于 n 所有子串组成的特征向量的余弦相似度（cosine similarity）；

- 直观上，两个字符串相同的子串越多，就越相似，字符串核函数的值就越大；

7.3.4 非线性支持向量机

- 将线性支持向量机扩展到非线性支持向量机，只需将线性支持向量机对偶形式中的内积换成核函数；
- **非线性支持向量机**定义：从非线性分类训练集，通过核函数与软间隔最大化，或凸二次规划学习得到的分类决策函数

$$f(x) = \text{sign} \left(\sum_{i=1}^N \alpha_i^* y_i K(x_i, x) + b^* \right) \quad (16)$$

称为非线性支持向量机， $K(x, z)$ 是正定核函数；

- **非线性支持向量机学习算法：**

1. **输入**训练数据集 T ；

2. 选取适当的核函数 $K(x, z)$ 和适当的参数 C ，构造并求解最优化问题，得到最优解 $\alpha^* = (\alpha_1^*, \alpha_2^*, \dots, \alpha_N^*)^T$ ；

$$\begin{aligned} \min_{\alpha} \quad & \frac{1}{2} \sum_{i=1}^N \sum_{j=1}^N \alpha_i \alpha_j y_i y_j K(x_i, x_j) - \sum_{i=1}^N \alpha_i \\ \text{s.t.} \quad & \sum_{i=1}^N \alpha_i y_i = 0 \\ & 0 \leq \alpha_i \leq C, \quad i = 1, 2, \dots, N \end{aligned}$$

3. 选择 α^* 中的一个正分量 $0 < \alpha_j^* < C$ ，计算

$$b^* = y_j - \sum_{i=1}^N \alpha_i^* y_i K(x_i, x_j) \quad (17)$$

4. 构造决策函数

$$f(x) = \text{sign} \left(\sum_{i=1}^N \alpha_i^* y_i K(x_i, x) + b^* \right) \quad (18)$$